



CANCRO DA MAMA

Em 2018, quase 2 milhões de novos casos de cancro da mama foram diagnosticados. Em2012, representou cerca de 12% de todos os novos casos de cancro e 25% de todos os cancro diagnosticados em pessoas do sexo feminino. Atualmente, o cancro da mama representa um em cada quatro de todos os cancros em mulheres. Desde 2008, a incidência mundial do cancro da mama aumentou em mais de 20% e a mortalidade aumentou 14%.

A REALIDADE DO CANCRO EM PORTUGAL O cancro é a segunda causa de morte em Portugal. A sua incidência aumenta, em média, 3% por ano no nosso país.

50.000



novos casos em 2018



1/4

Um quarto da população em Portugal corre o risco de desenvolver cancro até aos 75 anos e 10% poderão morrer desta doença.





COLORRETAL (10 mil novos doentes)



MAMA (7 mil portuguesas)



PRÓSTATA (6.600 homens) 0

dos óbitos em Portugal são causados por cancro

Fonte: Agência para a Investigação do Cancro da Organização Mundial da Saúde

ANÁLISE EXPLORATÓRIA


A base de dados foi extraída do repositório de Machine Learning da UCI, esta contem um total de 569 observações explicadas num total de 32 variáveis, nomeadamente:

- 1. ID
- 2. Diagnóstico (M = maligno, B = benigno)
- 3. Dez atributos calculados para cada núcleo da célula:
 - 1. Raio
 - 2. Textura
 - 3. Perímetro
 - 4. Área
 - 5. Suavidade
 - 6.Compactidade
 - 7. Concavidade
 - 8. Pontos côncavos
 - 9. Simetria
 - 10. Aproximação do litoral

id	diagnosis	radius_mean	texture_mean
Min. : 867		Min. : 6.981	
1st Qu.: 86921			
Median : 90602			
Mean : 3037183		Mean :14.127	
3rd Qu.: 881312		3rd Qu.:15.780	
Max. :91132050		Max. :28.110	
perimeter_mean	area_mean		ompactness_mean
Min. : 43.79	Min. : 143.5		in. :0.01938
1st Qu.: 75.17	1st Qu.: 420.3		st Qu.:0.06492
Median : 86.24	Median : 551.1		edian :0.09263
Mean : 91.97	Mean : 654.9		ean :0.10434
3rd Qu.:104.10	3rd Qu.: 782.7		rd Qu.:0.13040
Max. :188.50	Max. :2501.0		ax. :0.34540
concavity_mean	points_mean		dimension_mean
Min. :0.00000	Min. :0.00000		Min. :0.04996
1st Qu.:0.02956	1st Qu.:0.02031		1st Qu.:0.05770
Median :0.06154	Median :0.03350		Median :0.06154
Mean :0.08880	Mean :0.04892		Mean :0.06280
3rd Qu.:0.13070	3rd Qu.:0.07400		3rd Qu.:0.06612
Max. :0.42680	Max. :0.20120	Max. :0.3040	Max. :0.09744
radius_se	texture_se	perimeter_se	area_se
Min. :0.1115	Min. :0.3602	Min. : 0.757 Mi	n. : 6.802
1st Qu.:0.2324	1st Qu.:0.8339	1st Qu.: 1.606 1s	t Qu.: 17.850
Median :0.3242	Median :1.1080		dian : 24.530
Mean :0.4052	Mean :1.2169	Mean : 2.866 Me	an : 40.337
3rd Qu.:0.4789	3rd Qu.:1.4740		d Qu.: 45.190
Max. :2.8730	Max. :4.8850		x. :542.200
smoothness_se	compactness_se		points_se
Min. :0.001713			
1st Qu.:0.005169		80 1st Qu.:0.01509	
Median :0.006380			
Mean :0.007041			
3rd Ou.:0.008146			
Max. :0.031130			
symmetry_se	dimension_se	radius_worst	
Min. :0.007882			
1st Qu.:0.015160			1st Qu.:21.08
Median :0.018730			Median :25.41
Mean :0.020542	Mean :0.00379		Mean :25.68
3rd Qu.:0.023480			3rd Qu.:29.72
Max. :0.078950			Max. :49.54
perimeter_worst	area_worst	smoothness_worst c	
Min. : 50.41	Min. : 185.2		in. :0.02729
1st Qu.: 84.11	1st Qu.: 515.3		st Qu.:0.14720
Median : 97.66	Median : 686.5		edian :0.21190
Mean :107.26	Mean : 880.6		ean :0.25427
3rd Qu.:125.40	3rd Qu.:1084.0		rd Qu.:0.33910
Max. :251.20	Max. :4254.0		ax. :1.05800
concavity_worst	points_worst		imension_worst
Min. :0.0000	Min. :0.00000		in. :0.05504
1st Qu.:0.1145	1st Qu.:0.06493		st Qu.:0.07146
Median :0.2267	Median :0.09993	Median :0.2822 M	edian :0.08004
Mean :0.2722	Mean :0.11461	Mean :0.2901 M	ean :0.08395
3rd Qu.:0.3829	3rd Qu.:0.16140	3rd Qu.:0.3179 3	rd Qu.:0.09208
Max. :1.2520	Max. :0.29100	Max. :0.6638 M	ax. :0.20750

CORRELAÇÃO

Com base na matriz de correlação, observa-se que existem 13 preditores relacionados com a resposta "diagnosis", com $r \ge 0.6$, portanto pode-se inferir que existe uma boa relação entre estes preditores e a variável "alvo".




NORMALIZAÇÃO

Existem algumas variáveis que estão em escala diferentes (eg: texturemeanes, moothnessmean).

Para padronizar os valores das variáveis utilizou-se a função "scale", que é responsável por aplicar a função sobre os vetores do dataset para padronizar os valores numéricos, colocando-os na mesma escala.

Devido ao Teorema do Limite Central, sabe-se que as médias das amostras tendem a distribuir-se por uma distribuição normal.



MODELAÇÃO

1 Modelo

Dovianco Bosiduals:

Deviance Residuals	:					
Min	10	1	Median		3Q	Max
-1.595e-04 -2.100	e-08	-2.10	00e-08	2.1	L00e-08	1.461e-04
Coefficients:						
555-0.57						Pr(> z)
(Intercept)		1.942	41083.4	33.0	0.000	1.000
radius_mean		7.827			-0.002	0.998
texture_mean		4.307	26569.		0.004	0.997
perimeter_mean		4.416	650105.		0.001	0.999
area_mean		7.045	252722.3		0.003	0.998
smoothness_mean		3.852	19090.		0.005	0.996
compactness_mean	-50	1.788	119598.	941	-0.004	0.997
concavity_mean	28	0.525	80196.9	914	0.003	0.997
points_mean	9	4.553	81987.7	260	0.001	0.999
symmetry_mean	2	9.955	20902.7	749	0.000	1.000
dimension_mean	7	5.289	41398.	123	0.002	0.999
radius_se	7	4.479	87488.	042	0.001	0.999
texture_se		2.899	24040.	631	0.000	1.000
perimeter_se	8	3.533	76946.	504	0.001	0.999
area_se	-27	1.335	131353.	186	-0.002	0.998
smoothness_se	-4	9.039	31875.	388	-0.002	0.999
compactness_se	16	0.538	57058.	368	0.003	0.998
concavity_se	-7	5.970	70258.	679	-0.001	0.999
points_se	8	0.129	65409.	593	0.001	0.999
symmetry_se	-5	8.103	33556.	398	-0.002	0.999
dimension_se	-11	4.834	75442.	836	-0.002	0.999
radius_worst	115	2.857	323318.	827	0.004	0.997
texture_worst	-3	9.629	32725.	141	-0.001	0.999
perimeter_worst	-33	2.167	113655.	842	-0.003	0.998
area worst	-43	7.179	343529.	338	-0.001	0.999
smoothness worst	1000	2.621	36425.	559	0.000	1.000
compactness_worst	10	4.522	50814.7	755	0.002	0.998
concavity_worst		8.392	50493.0	620	-0.002	0.998
points_worst		0.818	47320.0	066	0.000	1.000
symmetry_worst		8.952	33063.		0.001	0.999
dimension_worst		9.513	47605.		0.001	0.999
(Dispersion parame	ter f	or bi	nomial fa	ami]	ly taken	to be 1)
Null deviance:	(F30) 70(A)			(2)		of freedom
Residual deviance:	2.15	60e-07	on 368	8 0	degrees	of freedom

Var1 Var2 Freq radius_mean perimeter_mean 0.9979 radius_worst perimeter_worst 0.9937 radius_mean area_mean 0.9874 perimeter_mean area mean 0.9865 radius_worst area_worst 0.9840 perimeter_worst area_worst 0.9776 radius_se perimeter_se 0.9728 perimeter_mean perimeter_worst 0.9704 radius mean radius worst 0.9695 radius_worst 0.9695 perimeter_mean radius_mean perimeter_worst 0.9651 radius_worst 0.9627 area_mean area mean area worst 0.9592 area_mean perimeter_worst 0.9591 radius_se area_se 0.9518 perimeter_mean area worst 0.9415 radius_mean area_worst 0.9411 perimeter_se area_se 0.9377 concavity_mean points_mean 0.9214 texture_worst 0.9120 texture_mean points_mean points_worst 0.9102

Correlação


2 Modelo

```
Deviance Residuals:
                  Median
                           0.0538
-2.1699 -0.1334
                 -0.0219
                                    3.4377
Coefficients:
                 Estimate Std. Error z value Pr(>|z|)
                  -1.52739
                             0.34669
                                     -4.406 1.06e-05 ***
(Intercept)
smoothness_mean
                 -0.06240
                                      -0.081 0.935699
compactness_mean
                  5.61340
                             1.36673
                                       4.107 4.01e-05 ***
                                      -1.459 0.144622
                  -0.82233
                             0.56370
symmetry_mean
dimension_mean
                  -4.89155
                             1.05443
                                      -4.639 3.50e-06 ***
texture_se
                  1.21057
                             0.34746
                                       3.484 0.000494 ***
                  0.76958
                             0.66114
                                       1.164 0.244415
smoothness se
compactness_se
                  -1.00976
                             1.29708
                                      -0.778 0.436283
                             1.44180 -1.721 0.085269
concavity_se
                  -2.48119
                             0.82504
                                       2.262 0.023713 *
points_se
                  1.86603
symmetry_se
                  -0.83034
                             0.59059
                                      -1.406 0.159737
dimension se
                  -0.32048
                             1.44962
                                      -0.221 0.825031
smoothness_worst -0.08558
                             0.82570
                                      -0.104 0.917453
compactness_worst -3.84131
                             1.93802 -1.982 0.047470 *
concavity_worst
                  4.53524
                             1.42838
                                      3.175 0.001498 **
symmetry_worst
                  2.02840
                             0.75159
                                      2.699 0.006958 **
dimension worst
                  2.68691
                             1.51713 1.771 0.076552 .
Signif. codes: 0 '*** 0.001 '** 0.01 '* 0.05 '.' 0.1 ' '1
(Dispersion parameter for binomial family taken to be 1)
    Null deviance: 527.28 on 398 degrees of freedom
Residual deviance: 110.15 on 382 degrees of freedom
AIC: 144.15
```


Primeiro Modelo após a analise da correlação


AIC: 62

Nº DE PREDITORES POR TÉCNICA DE AJUSTAMENTO



GRÁFICOS DOS PREDITORES MAIS RELEVANTES





MODELO LOGÍSTICO ESCOLHIDO

```
Deviance Residuals:
          test6_class
                                                       Min
                                                                10
                                                                      Median
conv loa6 0 1
                                                   -1.95634 -0.02183 -0.00199
                                                                             0.00003
                                                                                      2.86349
        0 105 4
                                                  Coefficients:
        1 2 59
                                                                  Estimate Std. Error z value Pr(>|z|)
                                                  (Intercept)
                                                                   0.3936
                                                                             2.0236
                                                                                    0.195 0.84576
                Accuracy: 0.9647
                                                  compactness_mean -3.4024
                                                                             2.7805
                                                                                   -1.224 0.22107
                   95% CI: (0.9248, 0.9869)
                                                  points_mean
                                                                   4.2922
                                                                             2.9816
                                                                                   1.440 0.14999
                                                  radius se
                                                                   4.8680
                                                                             9.7939
                                                                                    0.497 0.61916
    No Information Rate: 0.6294
                                                                  -1.6011
                                                  area_se
                                                                            19.1713 -0.084 0.93344
    P-Value [Acc > NIR] : <2e-16
                                                  smoothness_se
                                                                   0.9527
                                                                             0.7152 1.332 0.18286
                                                  compactness_se
                                                                  -1.5693
                                                                            1.4112 -1.112 0.26613
                                                  concavity_se
                                                                  -0.9775
                                                                            1.2339 -0.792 0.42822
                    Kappa: 0.9238
                                                                   4.2624
                                                  radius_worst
                                                                            16.7631
                                                                                    0.254 0.79928
                                                  texture_worst
                                                                   2.0257
                                                                            0.6500
                                                                                    3.116 0.00183 **
 Mcnemar's Test P-Value: 0.6831
                                                                   2.2841
                                                                            21.4729
                                                                                    0.106 0.91529
                                                  area_worst
                                                                   1.8598
                                                  points_worst
                                                                            2.2681
                                                                                    0.820 0.41221
                                                                   0.6588
                                                  symmetry_worst
                                                                             0.7388
                                                                                    0.892 0.37251
             Sensitivity: 0.9365
                                                                   2.6892
                                                  concavity_worst
                                                                            1.9816
                                                                                    1.357 0.17474
             Specificity: 0.9813
                                                  dimension_worst
                                                                   2.1129
                                                                            1.6491
                                                                                    1.281 0.20011
          Pos Pred Value: 0.9672
                                                  Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' '1
          Neg Pred Value: 0.9633
              Prevalence: 0.3706
                                                  (Dispersion parameter for binomial family taken to be 1)
          Detection Rate: 0.3471
   Detection Prevalence: 0.3588
                                                      Null deviance: 527.285 on 398 degrees of freedom
                                                  Residual deviance: 35.596 on 384 degrees of freedom
      Balanced Accuracy: 0.9589
                                                   AIC: 65.596
        'Positive' Class: 1
                                                  Number of Fisher Scoring iterations: 13
```

MODELO K-NEAREST NEIGHBORS (KNN)


Antes de gerar o modelo KNN é importante determinar o valor de K e para isso utiliza-se o Cross Validation para treinar diferentes subconjuntos de dados com diferentes valores de K de forma a identificar o K que possui uma melhor acurácia.

Após a preparação do dataset e a separação deste em dataset de treino e dados de teste, aplica-se a função KNN, obtendo a seguinte "Confusion Matrix".

```
Confusion Matrix and Statistics
             dados_teste_labels
modelo_knn_v1
            0 105
                  60
              Accuracy: 0.9706
                95% CI: (0.9327, 0.9904)
   No Information Rate: 0.6294
    P-Value [Acc > NIR] : <2e-16
                 Kappa: 0.9367
Mcnemar's Test P-Value : 1
           Sensitivity: 0.9524
           Specificity: 0.9813
        Pos Pred Value: 0.9677
        Neg Pred Value: 0.9722
             Prevalence: 0.3706
        Detection Rate: 0.3529
   Detection Prevalence: 0.3647
      Balanced Accuracy: 0.9668
       'Positive' Class: 1
```

"Confusion Matrix"

TABELA DE COMPARAÇÃO



	Accuracy	auc	aic
Logistic - M1	0.9176471	0.9117342	62
Logistic - M2	0.9470588	0.9416259	144.14862
Logistic - M3	0.9352941	0.9355437	168.65441
Logistic - M4	0.9588235	0.9477081	58.06722
Logistic - M5	0.9588235	0.9477081	62.04357
Logistic - M6	0.9647059	0.9589082	65.59571
KNN	0.9705882		

CONCLUSÃO

- O modelo de Regressão Logística e o modelo KNN possuem desempenhos semelhantes.
- Modelo logístico pode-se visualizar os coeficientes de todos os preditores o que permite uma análise mais completa.
- KNN apenas é possível identificar o Valor de k para o modelo

